



THUYẾT MINH

ĐỀ TÀI KHOA HỌC VÀ CÔNG NGHỆ CẤP SINH VIÊN 2026

A. THÔNG TIN CHUNG

A1. Tên đề tài

- Tên tiếng Việt (IN HOA): PHÁT HIỆN GIAN LẬN TÀI CHÍNH TỪ DỮ LIỆU CHUỖI THỜI GIAN BẰNG MÔ HÌNH ACRF-RNN KẾT HỢP APACHE SPARK VÀ PHÂN TÍCH ĐẶC TRƯNG TÀI CHÍNH THEO THỜI GIAN
- Tên tiếng Anh (IN HOA): FINANCIAL FRAUD DETECTION ON TEMPORAL FINANCIAL DATA USING ACRF-RNN WITH APACHE SPARK AND TEMPORAL FINANCIAL FEATURE ANALYSIS

A2. Thời gian thực hiện

..06.. tháng (kể từ khi được duyệt).

A3. Tổng kinh phí

Tổng kinh phí: ...6.. triệu đồng, gồm

- Kinh phí từ Trường Đại học Công nghệ Thông tin: ..6.. triệu đồng

A4. Chủ nhiệm

Họ và tên:

Ngày, tháng, năm sinh:

Số CMND:

; Ngày cấp:

Mã số sinh viên:

Số điện thoại liên lạc:

Đơn vị (Khoa):

Số tài khoản:

.

. Giới tính (Nam/Nữ):

; Nơi cấp:

.

.

.

Ngân hàng:

A5. Thành viên đề tài

TT	Họ tên	MSSV	Khoa
1	Nguyễn Thuý Ngân	23520996	Hệ thống thông tin
2	Nguyễn Trần Thảo Nguyên	23521052	Hệ thống thông tin

B. MÔ TẢ NGHIÊN CỨU

B1. Giới thiệu về đề tài

Gian lận tài chính trên báo cáo doanh nghiệp là một vấn đề có ảnh hưởng trực tiếp đến tính minh bạch của thị trường, quyền lợi của nhà đầu tư và hiệu quả giám sát của cơ quan quản lý. Các hành vi như thổi phồng doanh thu, ghi nhận sai lợi nhuận, che giấu nợ phải trả hoặc điều chỉnh bất thường các khoản mục kế toán có thể dẫn tới những quyết định đầu tư sai lệch và gây ra tổn thất kinh tế đáng kể. Trong bối cảnh dữ liệu tài chính của doanh nghiệp được lưu trữ qua nhiều năm và ngày càng phong phú, việc phát hiện gian lận chỉ dựa trên dữ liệu của một năm riêng lẻ dần bộc lộ hạn chế [1].

Các công trình gần đây cho thấy bài toán phát hiện gian lận tài chính đã được tiếp cận bằng nhiều hướng khác nhau, từ các mô hình học máy cổ điển đến các mô hình học sâu và mô hình đồ thị. Tuy nhiên, một số nghiên cứu vẫn chủ yếu xem dữ liệu của từng năm như các mẫu độc lập hoặc chỉ khai thác các quan hệ tương minh giữa doanh nghiệp ở mức hạn chế [2]–[5]. Bài báo nền tảng được lựa chọn cho đề tài này là “Attention-based Conditional Random Field for Financial Fraud Detection”, công bố tại IJCAI 2025. Bài báo chỉ ra hai hạn chế nổi bật của hướng tiếp cận hiện tại: nhiều phương pháp chưa khai thác đầy đủ mối liên hệ theo thời gian (temporal correlations) trong dữ liệu tài chính nhiều năm; đồng thời nhiều phương pháp vẫn xem các công ty là các thực thể độc lập, chưa mô hình hóa hiệu quả quan hệ ngầm giữa các công ty (implicit inter-company relationships) phản ánh sự tương đồng hành vi giữa các doanh nghiệp gian lận [1].

Để giải quyết hai hạn chế trên, tác giả đề xuất mô hình ACRF-RNN. Trong mô hình này, khối GRU được sử dụng để học biểu diễn theo chuỗi thời gian thông qua cơ chế cửa sổ trượt (sliding window); tiếp theo, attention-based CRF tinh chỉnh biểu diễn đặc trưng theo mức độ tương đồng hành vi giữa các công ty; cuối cùng, MLP thực hiện phân loại gian lận. Bài báo được đánh giá trên bộ dữ liệu thực gồm 491 công ty niêm yết trong giai đoạn 2010–2020, mỗi năm có 208 đặc trưng, và cho kết quả tốt hơn các phương pháp so sánh trên các chỉ số Accuracy, Recall, G-mean và KS [1]. Bên cạnh đó, bài báo có công bố mã nguồn và dữ liệu công khai, tạo điều kiện thuận lợi cho việc tái hiện thực nghiệm trong phạm vi đồ án sinh viên.

Dựa trên hướng dẫn đề tài và phạm vi thực hiện phù hợp với môn Dữ liệu lớn, đề tài này lựa chọn triển khai theo bốn ý chính: chọn bài báo nền làm nền tảng học thuật, tái hiện

thực nghiệm cơ bản của bài báo, sử dụng Apache Spark cho quy trình xử lý dữ liệu (pipeline), và xây dựng một hướng mở rộng riêng ở mức vừa phải dựa trên những nội dung bài báo chưa phân tích sâu. Việc dùng Spark không nhằm thay thế toàn bộ mô hình học sâu của bài báo, mà tập trung vào các bước đọc dữ liệu, làm sạch, chuẩn hóa, tổ chức dữ liệu theo công ty và năm, đồng thời chuyển đổi dữ liệu sang định dạng đầu vào phù hợp cho bước huấn luyện. Trong phạm vi hiện thực của đề tài, các bước tạo cửa sổ trượt và chia tập huấn luyện / kiểm định / kiểm thử được giữ theo logic của mã huấn luyện gốc để đảm bảo tính tương thích với thực nghiệm tái hiện. Bên cạnh đó, Spark được dùng để thực hiện một bước phân tích mở rộng về biến động đặc trưng tài chính theo thời gian, giúp đề tài không chỉ dừng ở tiền xử lý dữ liệu mà còn khai thác thêm các tín hiệu dữ liệu có khả năng liên quan đến gian lận.

Về khoảng trống nghiên cứu, bài báo đã giải quyết tốt việc khai thác mối liên hệ theo thời gian và quan hệ ngầm giữa các công ty trong phát hiện gian lận tài chính. Tuy nhiên, mô hình ACRF-RNN vẫn còn một khoảng trống đáng chú ý ở khía cạnh phân tích dữ liệu đầu vào và khả năng giải thích các tín hiệu tài chính theo thời gian. Cụ thể, bài báo mới chỉ minh họa khả năng giải thích mô hình ở phạm vi hạn chế, chẳng hạn trực quan hóa hệ số attention của một số attention head và sử dụng LIME cho một trường hợp gian lận tiêu biểu, nhưng chưa phân tích có hệ thống sự khác biệt của các đặc trưng tài chính giữa nhóm công ty gian lận và không gian lận qua từng năm. Bên cạnh đó, bài báo cũng chưa khảo sát sâu mức độ biến động của các đặc trưng tài chính qua các năm liên tiếp, ví dụ đặc trưng nào thay đổi mạnh trước hoặc gần thời điểm công ty bị gắn nhãn gian lận. Việc thiếu lớp phân tích dữ liệu này khiến người đọc khó nhận diện rõ hơn những tín hiệu tài chính nào có thể đóng vai trò quan trọng trong quá trình phát hiện gian lận. Vì vậy, đề tài dự kiến mở rộng theo hướng sử dụng Apache Spark để phân tích dữ liệu tài chính theo thời gian, bao gồm thống kê phân bố nhãn gian lận theo năm, so sánh mức chênh lệch đặc trưng giữa nhóm gian lận và không gian lận, đồng thời khảo sát xu hướng biến động của một số đặc trưng tài chính qua các năm liên tiếp. Hướng mở rộng này không nhằm thay thế mô hình ACRF-RNN, mà bổ sung một lớp phân tích dữ liệu có thể định lượng được, qua đó làm rõ hơn vai trò của các đặc trưng tài chính trong bài toán phát hiện gian lận và hỗ trợ nhận diện những biến động bất thường giữa nhóm công ty gian lận và không gian lận theo thời gian.

B2. Mục tiêu, nội dung, kế hoạch nghiên cứu

B2.1 Mục tiêu

Mục tiêu thứ nhất là tìm hiểu có hệ thống cơ sở lý thuyết liên quan đến bài toán phát hiện gian lận tài chính trên dữ liệu chuỗi thời gian, bao gồm đặc trưng dữ liệu tài chính, cơ chế cửa sổ trượt, khối GRU cho chuỗi thời gian, attention-based CRF, các chỉ số đánh giá Accuracy, Recallm, G-mean, KS và vai trò của Apache Spark trong quy trình xử lý dữ liệu.

Mục tiêu thứ hai là xây dựng được một quy trình xử lý dữ liệu bằng Apache Spark ở mức có thể minh chứng, bao gồm các bước đọc dữ liệu nguồn, kiểm tra và làm sạch dữ liệu, chuẩn hóa đặc trưng, tổ chức dữ liệu theo công ty và năm, và chuyển đổi dữ liệu sang định dạng đầu vào phù hợp cho bước huấn luyện theo thiết lập của bài báo nền. Trong phạm vi hiện thực của đề tài, các bước tạo cửa sổ trượt và chia tập huấn luyện / kiểm định / kiểm thử được giữ theo logic của mã huấn luyện gốc để đảm bảo tính tương thích với mô hình tái hiện. Tiêu chí thành công: quy trình xử lý dữ liệu trên Spark chạy từ đầu đến cuối không lỗi trên bộ dữ liệu gốc và tạo ra được các tệp đầu vào phục vụ bước huấn luyện mô hình.

Mục tiêu thứ ba là tái hiện được thực nghiệm cơ bản của bài báo ACRF-RNN trên bộ dữ liệu công khai của tác giả hoặc trên một phiên bản rút gọn tương đương về chức năng nếu phát sinh khó khăn kỹ thuật vượt ngoài phạm vi cho phép. Kết quả tái hiện sẽ được dùng để đối chiếu với mô tả trong bài báo nền. Tiêu chí thành công: đạt $KS \geq 35\%$ trên ít nhất một năm kiểm thử (bài báo gốc đạt $>40\%$), Recallm và G-mean trong khoảng $\pm 5\%$ so với bài báo.

Mục tiêu thứ tư là khảo sát một hướng mở rộng riêng của nhóm dựa trên những nội dung bài báo chưa phân tích sâu, tập trung vào việc sử dụng Apache Spark để phân tích đặc trưng tài chính theo thời gian. Cụ thể, đề tài xem xét phân bố nhãn gian lận theo năm, mức khác biệt của một số đặc trưng giữa nhóm công ty gian lận và không gian lận, cũng như mức biến động của đặc trưng tài chính qua các năm liên tiếp. Tiêu chí thành công: tạo được các bảng thống kê định lượng bằng Spark và rút ra nhận xét về những tín hiệu dữ liệu có thể hỗ trợ phát hiện gian lận.

B2.2 Nội dung và phương pháp nghiên cứu

Nội dung 1: Lựa chọn bài báo nền và khảo sát các công trình liên quan

- Mô tả: Khảo sát bài báo nền và một số công trình liên quan gần đây về phát hiện gian lận tài chính, mô hình chuỗi thời gian, mô hình đồ thị hoặc mô hình có sử dụng

quan hệ giữa các thực thể. Từ đó xác định rõ bài toán, dữ liệu, chỉ số đánh giá, phạm vi hiện thực và phần mở rộng khả thi của đề tài.

- Phương pháp nghiên cứu:
 - Đọc phần giới thiệu, kết luận, phương pháp và thực nghiệm của bài báo nền.
 - Khảo sát thêm một số công trình liên quan để nhận diện ưu điểm, hạn chế và khoảng trống còn lại.
 - Đối chiếu với yêu cầu môn học để chốt phạm vi thực hiện, tiêu chí đánh giá và sản phẩm đầu ra.
- Kết quả dự kiến: Có bản tổng hợp ngắn về tình hình hiện tại của bài toán; xác định được bài báo nền, khoảng trống nghiên cứu và phạm vi triển khai phù hợp của đề tài.

Nội dung 2: Tìm hiểu bộ dữ liệu và xây dựng quy trình xử lý bằng Apache Spark

- Mô tả: Tìm hiểu cấu trúc dữ liệu công khai đi kèm bài báo, ý nghĩa các nhóm đặc trưng và xây dựng quy trình xử lý dữ liệu bằng Apache Spark để chuẩn bị đầu vào cho bước thực nghiệm.
- Phương pháp nghiên cứu:
 - Tải bộ dữ liệu và mã nguồn công khai của tác giả; kiểm tra kiểu dữ liệu, giá trị thiếu và phân bố nhãn.
 - Sử dụng Spark để làm sạch dữ liệu, chuẩn hóa, sắp xếp theo công ty và năm, đồng thời chuyển đổi dữ liệu sang cấu trúc đầu vào phù hợp với mã huấn luyện gốc của tác giả.
 - Chia tập huấn luyện, kiểm định, kiểm thử và lưu dữ liệu sau xử lý sang định dạng phù hợp cho bước huấn luyện.
- Kết quả dự kiến: Có quy trình xử lý dữ liệu Spark chạy được trên bộ dữ liệu công khai; tạo ra được các tệp đầu vào phục vụ tái hiện thực nghiệm.

Nội dung 3: Tái hiện thực nghiệm cơ bản của bài báo

- Mô tả: Tái hiện thực nghiệm cốt lõi của bài báo ACRF-RNN dựa trên mã nguồn công khai và cấu hình thực nghiệm được công bố; trong trường hợp phát sinh lỗi phụ thuộc môi trường hoặc khó khăn ngoài dự kiến, đề tài ưu tiên tái hiện bản rút gọn giữ lại các thành phần chính về mô hình hóa theo thời gian và phân loại.
- Phương pháp nghiên cứu:

- Dựn dựng môi trường chạy, kiểm tra khả năng đọc dữ liệu, huấn luyện và suy luận của mã nguồn công khai.
- Ghi nhận các tham số chính như kích thước cửa sổ thời gian, số đầu chú ý (attention heads), số vòng lặp CRF và các chỉ số đánh giá.
- Đối chiếu kết quả thu được với mô tả trong bài báo và phân tích sai khác nếu có.
- Kết quả dự kiến: Có kết quả tái hiện ở mức cơ bản hoặc một phiên bản rút gọn chạy ổn định; thu được bảng kết quả thực nghiệm ban đầu và các ghi chú về khó khăn kỹ thuật.

Nội dung 4: Khảo sát mở rộng bằng Spark về đặc trưng tài chính theo thời gian

- Mô tả: Từ quy trình xử lý dữ liệu và kết quả tái hiện, đề tài khảo sát bước đầu một số tín hiệu dữ liệu mà bài báo nền chưa phân tích có hệ thống, bao gồm phân bố gian lận theo năm, sự khác biệt giữa nhóm công ty gian lận và không gian lận, và mức biến động của các đặc trưng tài chính qua các năm liên tiếp. Phần mở rộng này không đặt mục tiêu thay đổi kiến trúc ACRF-RNN, mà tập trung làm rõ vai trò của Apache Spark trong phân tích dữ liệu tài chính nhiều năm và tạo ra các bảng thống kê phục vụ nhận xét thực nghiệm.
- Phương pháp nghiên cứu:
 - Thiết kế một số phép thử ở phạm vi vừa phải như thống kê tỷ lệ gian lận theo năm, so sánh giá trị trung bình hoặc độ lệch của các đặc trưng giữa nhóm gian lận/không gian lận (fraud/benign), và xác định các đặc trưng có mức chênh lệch hoặc biến động lớn qua các năm liên tiếp.
 - Sử dụng Spark để xử lý dữ liệu theo nhóm công ty và năm, tính các thống kê mô tả, mức thay đổi đặc trưng giữa năm $t-1$ và năm t , và xuất các bảng kết quả như phân bố nhãn theo năm, top đặc trưng khác biệt giữa nhóm gian lận/không gian lận (fraud/benign), hoặc bảng sự thay đổi/phân bố lệch đi của các đặc trưng dữ liệu (feature drift) theo thời gian.
 - Đánh giá định tính và định lượng ý nghĩa của các đặc trưng/biến động nổi bật đối với bài toán phát hiện gian lận; đối chiếu ở mức nhận xét với kết quả tái hiện ACRF-RNN và các phân tích giải thích mô hình được nêu trong bài báo nền.
- Kết quả dự kiến: Có ít nhất một bảng thống kê hoặc nhận xét định lượng về hướng mở rộng bằng Spark, chẳng hạn bảng phân bố gian lận/không gian lận

(fraud/benign) theo năm, bảng top đặc trưng khác biệt giữa nhóm gian lận và không gian lận, hoặc bảng biến động đặc trưng qua các năm liên kề; rút ra kết luận về tính phù hợp của việc khai thác đặc trưng tài chính theo thời gian trong phạm vi đồ án sinh viên.

B2.3 Kế hoạch nghiên cứu.

Kế hoạch nghiên cứu	Thời gian	Mô tả
Nội dung 1: Lựa chọn bài báo nền và khảo sát các công trình liên quan	2 tuần	Đọc bài báo nền, khảo sát các công trình liên quan, xác định bài toán, khoảng trống và phạm vi triển khai.
Nội dung 2: Tìm hiểu bộ dữ liệu và xây dựng quy trình xử lý bằng Apache Spark	6 tuần	Phân tích dữ liệu công khai, làm sạch, chuẩn hóa, sắp xếp theo công ty và năm, chuyển đổi dữ liệu sang định dạng đầu vào phù hợp cho mã huấn luyện gốc.
Nội dung 3: Tái hiện thực nghiệm cơ bản của bài báo	8 tuần	Dựng môi trường, kiểm tra mã nguồn công khai, chạy thực nghiệm cơ bản hoặc bản rút gọn tương đương, ghi nhận các chỉ số đánh giá.
Nội dung 4: Khảo sát mở rộng bằng Spark về đặc trưng tài chính theo thời gian	4 tuần	Thiết kế và thực hiện các thống kê mở rộng bằng Spark như phân bố gian lận theo năm, top đặc trưng khác biệt giữa nhóm fraud/benign và biến động đặc trưng qua các năm liên kề; tổng hợp bảng kết quả và nhận xét định lượng.

Tổng hợp kết quả, hoàn thiện báo cáo, slide và tài liệu cài đặt	4 tuần	Tổng hợp kết quả, viết báo cáo cuối kỳ, chuẩn bị slide trình bày, hoàn thiện hướng dẫn cài đặt và chạy thử.
Tổng cộng	24 tuần	

B3. Kết quả dự kiến

- Tìm hiểu được cơ sở lý thuyết liên quan đến bài toán phát hiện gian lận tài chính trên dữ liệu chuỗi thời gian, mô hình ACRF-RNN, các chỉ số đánh giá và vai trò của Apache Spark trong quy trình xử lý dữ liệu.
- Xây dựng được một quy trình xử lý dữ liệu bằng Apache Spark có thể chạy được trên bộ dữ liệu công khai của tác giả, bao gồm các bước đọc dữ liệu, làm sạch, chuẩn hóa, tổ chức theo công ty và năm, và chuyển đổi dữ liệu sang định dạng đầu vào phù hợp cho mã huấn luyện gốc, trong đó cơ chế tạo cửa sổ trượt và chia tập dữ liệu được giữ theo logic của mã thực nghiệm để đảm bảo tính tương thích với bước tái hiện mô hình.
- Tái hiện được thực nghiệm cơ bản của bài báo ACRF-RNN hoặc một phiên bản rút gọn tương đương về chức năng trong trường hợp phát sinh khó khăn kỹ thuật, kèm theo bảng kết quả và nhận xét đối chiếu với bài báo nền.
- Có được ít nhất một phép thử mở rộng bằng Spark dựa trên những nội dung bài báo chưa phân tích sâu, chẳng hạn phân tích phân bố gian lận theo năm, top đặc trưng khác biệt giữa nhóm gian lận/không gian lận (fraud/benign) hoặc mức biến động đặc trưng tài chính qua các năm liên kề; từ đó rút ra nhận xét định lượng về vai trò của phân tích đặc trưng tài chính theo thời gian trong bài toán phát hiện gian lận.
- Hoàn thành một bộ báo cáo gồm đề cương nghiên cứu, báo cáo cuối kỳ, slide trình bày, mã nguồn minh họa, dữ liệu đã xử lý và hướng dẫn cài đặt/chạy thử phục vụ báo cáo môn học.

B4. Tài liệu tham khảo

- [1] X. Wang, C. Wang, L. Zhang, X. Wang, M. Wang, H. Liu, and T. Qin, “Attention-based Conditional Random Field for Financial Fraud Detection,” in Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence (IJCAI-25), 2025, pp. 7822–7830.
- [2] C. Wang, M. Wang, X. Wang, L. Zhang, and Y. Long, “Multi-relational graph representation learning for financial statement fraud detection,” Big Data Mining and Analytics, vol. 7, no. 3, pp. 920–941, 2024.
- [3] X. Wang, C. Wang, H. Liu, M. Wang, T. Qin, and P. Wang, “FiGraph: A dynamic heterogeneous graph dataset for financial anomaly detection,” in Companion Proceedings of the ACM Web Conference 2025, 2025, pp. 813–816.
- [4] Y. Liu, Z. Sun, and W. Zhang, “Improving fraud detection via hierarchical attention-based graph neural network,” Journal of Information Security and Applications, vol. 72, Art. no. 103399, 2023.
- [5] B. Xu, H. Shen, B. Sun, R. An, Q. Cao, and X. Cheng, “Towards consumer loan fraud detection: Graph neural networks with role-constrained conditional random field,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 35, 2021, pp. 4537–4545.

Ngày 25 tháng 04 năm 2026

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)

Ngày 25 tháng 04 năm 2026

Chủ nhiệm đề tài

(Ký và ghi rõ họ tên)

Nguyễn Hồ Duy Trí